IE212 – CÔNG NGHỆ DỮ LIỆU LỚN
LAB 2: SPARK RDD

GVTH: Nguyễn Thị Hoàng Anh

Họ và tên: Nguyễn Minh Tuấn
MSSV: 23521720
Lớp: IE212.R12.1

Mục lục

B. Bài tập bắt buộc 2
Bài 1. Đọc dữ liệu và kiểm tra 2
Bài 2. Sân bay bận rộn nhất 2
Bài 3. Số hãng bay khai thác mỗi sân bay 3
Bài 4. Thống kê theo loại máy bay 4
Bài 5. Số đường bay theo quốc gia 5
Bài 6. Mạng bay Việt Nam 6
C. Bài tập tự chọn 10
Bài 7. Nội địa so với quốc tế trên toàn thế giới 10

Bài làm

B. Bài tập bắt buộc

Bài 1. Đọc dữ liệu và kiểm tra

- **Phương pháp:** Sử dụng sc.textFile() để đọc ba tệp routes.dat, airports.dat và airlines.dat vào RDD. Dùng split(",") để tách dữ liệu đường bay và csv.reader() để xử lý dữ liệu sân bay, hãng bay. Sau đó sử dụng count() để đếm số dòng và filter() để kiểm tra mã IATA hợp lệ cũng như tên sân bay chứa dấu phẩy.
- **Kết quả thực hiện:**

```
routes : 67663 dong, 9 cot
airports : 7698 dong, 14 cot
airlines : 6162 dong, 8 cot
San bay co ma IATA hop le: 6071
Ten san bay co chua dau phay: 16
```

- **Nhận xét kết quả:** Dữ liệu gồm 67.663 đường bay (9 cột), 7.698 sân bay (14 cột) và 6.162 hãng bay (8 cột). Trong đó có 6.071 sân bay có mã IATA hợp lệ và 16 tên sân bay chứa dấu phẩy. Các kết quả đều khớp với số liệu mong đợi.
- **Giải thích**: vì sao routes.dat tách được bằng split còn hai tệp tra cứu thì không?
    - Tệp routes.dat không có dấu phẩy nằm trong giá trị nên có thể dùng split(",") để tách dữ liệu.
    - Ngược lại, airports.dat và airlines.dat có các trường chứa dấu phẩy được đặt trong dấu nháy kép.

➔ Vì vậy cần sử dụng csv.reader() để tách đúng các cột, tránh làm sai cấu trúc dữ liệu.

Bài 2. Sân bay bận rộn nhất

- **Phương pháp:** Sử dụng map() để tạo các cặp (mã sân bay, 1) từ cột sân bay đi và sân bay đến. Sau đó dùng reduceByKey() để đếm số đường bay của từng sân bay. Sắp xếp kết quả giảm dần bằng takeOrdered() và sử dụng bảng tra sân bay đã broadcast để lấy thông tin thành phố, quốc gia.
- **Kết quả thực hiện:**

```
So san bay co duong bay di: 3409
So san bay co duong bay den: 3418
Tong duong bay di: 67663
Tong duong bay den: 67663

Top 10 san bay co nhieu duong bay di:
ATL    915    Atlanta, United States
ORD    558    Chicago, United States
PEK    535    Beijing, China
LHR    527    London, United Kingdom
CDG    524    Paris, France
FRA    497    Frankfurt, Germany
LAX    492    Los Angeles, United States
DFW    469    Dallas-Fort Worth, United States
JFK    456    New York, United States
AMS    453    Amsterdam, Netherlands
```

- **Nhận xét kết quả:** Có 3.409 sân bay có đường bay đi và 3.418 sân bay có đường bay đến. ATL đứng đầu với 915 đường bay đi, tiếp theo là ORD với 558 và PEK với 535 đường bay. Tổng số đường bay đi và đến đều bằng 67.663, khớp với tổng số dòng dữ liệu.
- **Giải thích**: chênh lệch giữa 3.409 sân bay có chuyến đi và 3.418 sân bay có chuyến đến

  ➔ Sự chênh lệch giữa 3.409 sân bay đi và 3.418 sân bay đến là do tập hợp sân bay xuất hiện ở hai chiều không hoàn toàn giống nhau. Một số sân bay chỉ xuất hiện ở điểm đi hoặc điểm đến trong dữ liệu, khiến số lượng sân bay phân biệt ở hai nhóm khác nhau.

Bài 3. Số hãng bay khai thác mỗi sân bay

- **Phương pháp:** Sử dụng map() để tạo các cặp (sân bay đi, hãng bay), sau đó dùng distinct() để loại bỏ những cặp trùng lặp. Tiếp theo dùng reduceByKey() để đếm số hãng khác nhau tại mỗi sân bay và takeOrdered() để lấy 10 sân bay dẫn đầu.
- **Kết quả thực hiện:**

```
So cap (san bay, hang bay) khac nhau: 19288
So san bay chi co 1 hang: 1313
So hang khai thac tai ATL: 37

Top 10 san bay:
CDG  108 hang   524 duong bay   Paris, France
FRA  100 hang   497 duong bay   Frankfurt, Germany
BKK   98 hang   326 duong bay   Bangkok, Thailand
FCO   92 hang   331 duong bay   Rome, Italy
LHR   86 hang   527 duong bay   London, United Kingdom
DXB   84 hang   356 duong bay   Dubai, United Arab Emirates
HKG   83 hang   355 duong bay   Hong Kong, Hong Kong
SIN   83 hang   408 duong bay   Singapore, Singapore
PEK   81 hang   535 duong bay   Beijing, China
AMS   79 hang   453 duong bay   Amsterdam, Netherlands
```

- **Nhận xét kết quả:** Từ 67.663 đường bay thu được 19.288 cặp sân bay–hãng bay khác nhau. CDG đứng đầu với 108 hãng, tiếp theo là FRA với 100 hãng và BKK với 98 hãng. Ngoài ra, có 1.313 sân bay chỉ có một hãng khai thác.
- **Giải thích**: vì sao ATL có 915 chuyến nhưng không lọt bảng này?

  ➔ ATL có 915 đường bay đi nhưng chỉ có 37 hãng bay khác nhau khai thác. Trong khi đó, Bài 3 xếp hạng dựa trên số hãng bay phân biệt, không phải tổng số đường bay. Vì vậy ATL không nằm trong Top 10 mặc dù có số đường bay đi lớn nhất.

Bài 4. Thống kê theo loại máy bay

- **Phương pháp:** Sử dụng flatMap() để tách các mã máy bay trong cột Equipment thành từng phần tử riêng biệt, sau đó dùng reduceByKey() để đếm số lần xuất hiện của từng loại máy bay. Kết quả được sắp xếp giảm dần để lấy 12 loại phổ biến nhất.
- **Kết quả thực hiện:**

```
Chuyen co khai bao may bay : 67645
Chuyen khong khai bao may bay : 18
Tong cap (duong bay, may bay): 93231
So loai may bay khac nhau: 168
Nhieu loai may bay nhat tren 1 chuyen: 9

Top 12 loai may bay:
320   15514
738   10406
319   7885
321   3677
73H   3351
737   2787
73W   2502
CRJ   2224
E90   1970
AT7   1635
73G   1592
333   1589
```

- **Nhận xét kết quả:**
  - Có 67.645 đường bay khai báo loại máy bay và 18 đường bay không có thông tin. Sau khi tách thu được 93.231 cặp đường bay–loại máy bay thuộc 168 loại khác nhau. Loại 320 phổ biến nhất với 15.514 lần xuất hiện, tiếp theo là 738 với 10.406 lần và 319 với 7.885 lần.
  - Tổng số cặp lớn hơn số đường bay vì một đường bay có thể được khai thác bằng nhiều loại máy bay khác nhau.
- **Giải thích**: nêu cách xử lý 18 đường bay có cột Equipment rỗng

  ➔ Đối với 18 đường bay có Equipment rỗng, chương trình không đưa chúng vào thống kê theo loại máy bay vì không có mã để phân loại. Tuy nhiên, các đường bay này vẫn được giữ trong RDD gốc và được tính vào tổng số 67.663 đường bay.

Bài 5. Số đường bay theo quốc gia

- **Phương pháp:** Sử dụng bảng tra sân bay được tạo bằng collectAsMap() và phân phối bằng sc.broadcast() để xác định quốc gia của sân bay xuất phát. Sau đó dùng map() và reduceByKey() để đếm số đường bay theo quốc gia. Những đường bay không tra được mã sân bay đi được thống kê riêng.
- **Kết quả thực hiện:**

```
So quoc gia: 225
Chuyen khong tra duoc san bay di: 406
So ma san bay khong tra duoc san bay di: 157
Kiem tra: 67257 + 406 = 67663

Top 12 quoc gia:
United States           13100
China                   8160
United Kingdom          2663
Spain                   2531
Germany                 2352
France                  1930
Canada                  1852
Russia                  1843
Italy                   1776
India                   1507
Brazil                  1398
Japan                   1286
```

- **Nhận xét kết quả:**
  - Có 225 quốc gia được thống kê. United States đứng đầu với 13.100 đường bay, tiếp theo là China với 8.160 và United Kingdom với 2.663 đường bay.
  - Có 406 đường bay thuộc 157 mã sân bay không tra cứu được. Tổng số đường bay hợp lệ và không tra cứu được là 67.257 + 406 = 67.663, khớp với tổng dữ liệu ban đầu.

Bài 6. Mạng bay Việt Nam

- **Phương pháp:** Sử dụng filter() kết hợp bảng tra sân bay broadcast để lọc các đường bay có sân bay xuất phát thuộc Việt Nam. Tiếp theo, so sánh quốc gia của sân bay đi và đến để phân loại đường bay nội địa và quốc tế. Sử dụng reduceByKey() để thống kê số đường bay theo sân bay và hãng hàng không, đồng thời tra tên hãng từ airlines.dat.
- **Kết quả thực hiện:**

```
Chuyen bay di tu VN: 288
Chuyen bay den VN: 288
Chuyen bay noi dia: 126
Chuyen bay quoc te di: 162
Trong do khong tra duoc san bay den: 1

So san bay co chuyen bay di: 20

SGN  109  Ho Chi Minh City
HAN   87  Hanoi
DAD   33  Danang
BMV    7  Buonmethuot
CXR    7  Nha Trang
VII    7  Vinh
DLI    5  Dalat
PQC    5  Phuquoc
HPH    4  Haiphong
HUI    4  Hue
PXU    3  Pleiku
UIH    3  Phucat
VCA    3  Can Tho
TBB    2  Tuy Hoa
VCL    2  Chu Lai
VCS    2  Conson
VDH    2  Dong Hoi
CAH    1  Ca Mau
DIN    1  Dienbienphu
VKG    1  Rach Gia
```

```
So hang bay: 45

VN   139  Vietnam Airlines
VJ    32  Royal Air Cambodge
BL    18  Jetstar Pacific
JL     8  Japan Airlines
KE     5  Korean Air
K6     4  Cambodia Angkor Air (K6)
MU     4  China Eastern Airlines
CZ     4  China Southern Airlines
SQ     4  Singapore Airlines
AZ     4  Alitalia
AF     3  Air France
CX     3  Cathay Pacific
CI     3  China Airlines
OZ     3  Asiana Airlines
QV     3  Lao Airlines
QR     3  Qatar Airways
MI     3  SilkAir
SU     2  Aeroflot Russian Airlines
5J     2  Cebu Pacific
KA     2  Dragonair
BR     2  EVA Air
AA     2  American Airlines
HX     2  Hong Kong Airlines
NX     2  Air Macau
NH     2  All Nippon Airways
MH     2  Malaysia Airlines
AE     2  Mandarin Airlines
QF     2  Qantas
TR     2  Tiger Airways
TG     2  Thai Airways International
```

```
FD     2  Thai AirAsia
VA     2  Virgin Australia
AK     2  AirAsia
B7     2  Uni Air
KC     1  Air Astana
EK     1  Emirates
EY     1  Etihad Airways
3K     1  Jetstar Asia Airways
JT     1  Lion Mentari Airlines
PR     1  Philippine Airlines
3U     1  Sichuan Airlines
TK     1  Turkish Airlines
UN     1  Transaero Airlines
UA     1  United Airlines
CA     1  Air China
```

- **Nhận xét kết quả:**
  - Có 288 đường bay xuất phát từ Việt Nam và 288 đường bay đến Việt Nam. Trong số đường bay đi, có 126 đường bay nội địa và 162 đường bay còn lại theo cách phân loại của đề.
  - Việt Nam có 20 sân bay xuất hiện trong danh sách đường bay đi. SGN dẫn đầu với 109 đường bay, tiếp theo là HAN với 87 và DAD với 33 đường bay.
  - Có 45 hãng hàng không khai thác đường bay xuất phát từ Việt Nam. Ba hãng có nhiều đường bay nhất là VN (139), VJ (32) và BL (18).
- **Giải thích**: Nhận xét về việc số đường bay đi và số đường bay đến đều bằng 288
  Giải thích về 1 đường bay chưa tra được sân bay đến
  - **Về số đường bay đi và đến:** Cả hai đều bằng 288 cho thấy số lượng đường bay ở hai chiều cân bằng về tổng thể. Tuy nhiên, điều này không có nghĩa mọi đường bay đều có tuyến ngược lại tương ứng hoặc số chuyến bay thực tế ở hai chiều bằng nhau.
  - **Về đường bay không tra cứu được:** Trong 162 đường bay được xếp vào nhóm không nội địa, có một đường bay SGN → THD không tra cứu được quốc gia của sân bay đến trong bảng airports.dat. Do đó, thực tế có 161 đường bay được xác định chắc chắn là quốc tế và 1 đường bay chưa thể phân loại. Kết quả 162 trong đề được tính bằng cách lấy tổng số đường bay đi trừ số đường bay nội địa.

C. Bài tập tự chọn

Bài 7. Nội địa so với quốc tế trên toàn thế giới

- **Phương pháp:** Sử dụng bảng tra sân bay broadcast để xác định quốc gia của sân bay đi và sân bay đến. Dùng map() để phân loại mỗi đường bay thành nội địa, quốc tế hoặc không tra cứu được, sau đó dùng reduceByKey() để đếm số lượng của từng nhóm. Tỉ lệ quốc tế được tính trên tổng số đường bay xác định được cả hai quốc gia..
- **Kết quả thực hiện:**

```
Noi dia: 32167
Quoc te: 34767
Khong tra duoc: 729
Tong: 67663
Ti le quoc te: 51.9%
```

- **Nhận xét kết quả:**
  - Có 32.167 đường bay nội địa, 34.767 đường bay quốc tế và 729 đường bay không tra cứu được. Tổng cộng là 67.663 đường bay, khớp với dữ liệu ban đầu.
  - Tỉ lệ đường bay quốc tế chiếm khoảng 51,9% trong số các đường bay phân loại được, cao hơn một chút so với đường bay nội địa.
- **Giải thích**: vì sao số đường bay không tra được tăng từ 406 lên 729?

  ➔ Số đường bay không tra cứu được tăng từ 406 ở Bài 5 lên 729 ở Bài 7 vì Bài 5 chỉ yêu cầu xác định quốc gia của sân bay đi, trong khi Bài 7 cần xác định quốc gia ở cả sân bay đi và sân bay đến. Nếu thiếu thông tin ở một trong hai đầu, đường bay sẽ được xếp vào nhóm không tra cứu được.