IE212 – CÔNG NGHỆ DỮ LIỆU LỚN
LAB 3: SPARK DATAFRAME

GVTH: Nguyễn Thị Hoàng Anh

Họ và tên: Nguyễn Minh Tuấn
MSSV: 23521720
Lớp: IE212.R12.1

Mục lục

B. Bài tập bắt buộc 2
Bài 1. Đọc dữ liệu và kiểm tra lược đồ 2
Bài 2. Thống kê tổng số đơn hàng, khách hàng và người bán 4
Bài 3 Số đơn hàng theo quốc gia 5
Bài 4. Số đơn hàng theo năm và tháng 6
Bài 5. Điểm đánh giá trung bình và phân bố theo mức 8
Bài 6. Xếp hạng người bán 9
C. Bài tập tự chọn 11
Bài 7. Doanh thu năm 2024 theo danh mục sản phẩm 11
Bài 8. Sản phẩm bán chạy nhất và điểm đánh giá trung bình 13
D. Bảng so sánh 3 công nghệ 15

Bài làm

B. Bài tập bắt buộc

Bài 1. Đọc dữ liệu và kiểm tra lược đồ

- **Phương pháp:**
  - Sử dụng spark.read.csv() để đọc 5 tệp dữ liệu Fecom vào DataFrame với các tùy chọn sep=";", header=True và inferSchema=True. Riêng Order_Reviews.csv sử dụng thêm multiLine=True và escape="" để xử lý các bình luận chứa dấu xuống dòng và dấu nháy kép.
  - Sau khi đọc, tiến hành chuẩn hóa tên cột để loại bỏ BOM, sử dụng printSchema() kiểm tra kiểu dữ liệu và count() để thống kê số dòng. Đồng thời, kiểm tra các cột thời gian và thực hiện chuyển đổi sang kiểu timestamp nếu cần.

- **Kết quả thực hiện:**

```
Orders
root
 |-- Order_ID: string (nullable = true)
 |-- Customer_Trx_ID: string (nullable = true)
 |-- Order_Status: string (nullable = true)
 |-- Order_Purchase_Timestamp: timestamp (nullable = true)
 |-- Order_Approved_At: timestamp (nullable = true)
 |-- Order_Delivered_Carrier_Date: timestamp (nullable = true)
 |-- Order_Delivered_Customer_Date: timestamp (nullable = true)
 |-- Order_Estimated_Delivery_Date: timestamp (nullable = true)


Order_Items
root
 |-- Order_ID: string (nullable = true)
 |-- Order_Item_ID: integer (nullable = true)
 |-- Product_ID: string (nullable = true)
 |-- Seller_ID: string (nullable = true)
 |-- Shipping_Limit_Date: timestamp (nullable = true)
 |-- Price: double (nullable = true)
 |-- Freight_Value: double (nullable = true)

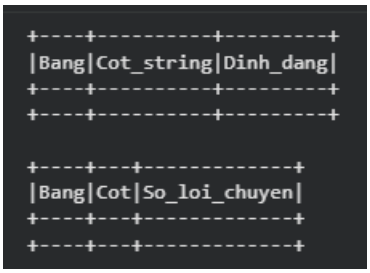

Products
root
 |-- Product_ID: string (nullable = true)
 |-- Product_Category_Name: string (nullable = true)
 |-- Product_Weight_Gr: integer (nullable = true)
 |-- Product_Length_Cm: integer (nullable = true)
 |-- Product_Height_Cm: integer (nullable = true)
 |-- Product_Width_Cm: integer (nullable = true)


Customer_List
root
 |-- Customer_Trx_ID: string (nullable = true)
 |-- Subscriber_ID: string (nullable = true)
 |-- Subscribe_Date: date (nullable = true)
 |-- First_Order_Date: date (nullable = true)
 |-- Customer_Postal_Code: string (nullable = true)
 |-- Customer_City: string (nullable = true)
 |-- Customer_Country: string (nullable = true)
 |-- Customer_Country_Code: string (nullable = true)
 |-- Age: integer (nullable = true)
 |-- Gender: string (nullable = true)
```

```
Order_Reviews
root
 |-- Review_ID: string (nullable = true)
 |-- Order_ID: string (nullable = true)
 |-- Review_Score: integer (nullable = true)
 |-- Review_Comment_Title_En: string (nullable = true)
 |-- Review_Comment_Message_En: string (nullable = true)
 |-- Review_Creation_Date: timestamp (nullable = true)
 |-- Review_Answer_Timestamp: timestamp (nullable = true)
```

Bang	So_dong	Moc_doi_chieu
Orders	99441	99441
Order_Items	112650	112650
Products	32951	32951
Customer_List	102727	102727
Order_Reviews	99223	99223

Bang	Cot	Kieu_suy_ra
Orders	Order_ID	string
Orders	Customer_Trx_ID	string
Orders	Order_Status	string
Orders	Order_Purchase_Timestamp	timestamp
Orders	Order_Approved_At	timestamp
Orders	Order_Delivered_Carrier_Date	timestamp
Orders	Order_Delivered_Customer_Date	timestamp
Orders	Order_Estimated_Delivery_Date	timestamp
Order_Items	Order_ID	string
Order_Items	Order_Item_ID	int
Order_Items	Product_ID	string
Order_Items	Seller_ID	string
Order_Items	Shipping_Limit_Date	timestamp
Order_Items	Price	double
Order_Items	Freight_Value	double
Products	Product_ID	string
Products	Product_Category_Name	string
Products	Product_Weight_Gr	int
Products	Product_Length_Cm	int
Products	Product_Height_Cm	int
Products	Product_Width_Cm	int
Customer_List	Customer_Trx_ID	string
Customer_List	Subscriber_ID	string
Customer_List	Subscribe_Date	date
Customer_List	First_Order_Date	date
Customer_List	Customer_Postal_Code	string
Customer_List	Customer_City	string
Customer_List	Customer_Country	string
Customer_List	Customer_Country_Code	string
Customer_List	Age	int
Customer_List	Gender	string
Order_Reviews	Review_ID	string
Order_Reviews	Order_ID	string
Order_Reviews	Review_Score	int
Order_Reviews	Review_Comment_Title_En	string
Order_Reviews	Review_Comment_Message_En	string
Order_Reviews	Review_Creation_Date	timestamp
Order_Reviews	Review_Answer_Timestamp	timestamp



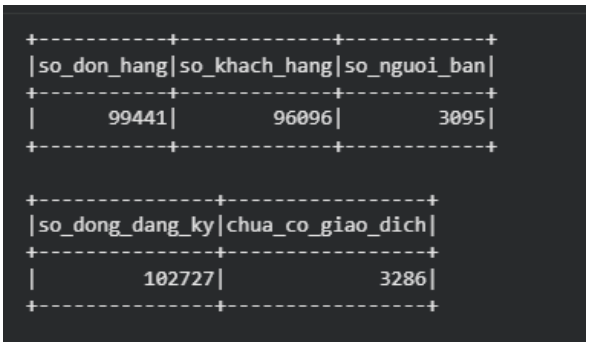
- **Nhận xét kết quả:**
  - Cả 5 bảng đều được đọc thành công với số dòng lần lượt là 99.441, 112.650, 32.951, 102.727 và 99.223, khớp với dữ liệu mong đợi.
  - Spark tự suy luận đúng các kiểu dữ liệu cơ bản như integer, double và string. Đáng chú ý, các cột thời gian được nhận diện trực tiếp dưới dạng timestamp hoặc date, thay vì string như trường hợp được đề cập trong tài liệu hướng dẫn. Điều này cho thấy việc suy luận kiểu dữ liệu có thể phụ thuộc vào môi trường và phiên bản Spark đang sử dụng.

- **Giải thích hai bảng output trống**:
  - Ở cell thứ hai của Bài 1, chương trình chỉ thống kê những cột thời gian được Spark nhận diện là string để thực hiện chuyển đổi và kiểm tra lỗi định dạng.
  - Do các cột thời gian đã được tự động nhận diện là timestamp hoặc date, không có cột nào thỏa mãn điều kiện kiểm tra. Vì vậy, hai bảng Cot_string và So_loi_chuyen không xuất hiện bản ghi nào.
  - Đây là kết quả bình thường, không phải lỗi thực thi hay thiếu dữ liệu. Tuy nhiên, hai bảng trống chỉ cho biết không có cột thời gian dạng chuỗi cần chuyển đổi, không khẳng định tất cả giá trị thời gian đều không có NULL.

Bài 2. Thống kê tổng số đơn hàng, khách hàng và người bán

- **Phương pháp:**
  - Sử dụng count() để đếm tổng số đơn hàng từ bảng Orders. Với khách hàng, thực hiện đối chiếu các giao dịch giữa Orders và Customer_List bằng left_semi join, sau đó sử dụng countDistinct("Subscriber_ID") để đếm số người thực sự đã mua hàng.
  - Số người bán được tính bằng countDistinct("Seller_ID") trên bảng Order_Items. Ngoài ra, kiểm tra các bản ghi có Customer_Trx_ID bằng NULL để xác định số người đăng ký nhưng chưa phát sinh giao dịch.

- **Kết quả thực hiện:**



```
+-----------+-------------+------------+
|so_don_hang|so_khach_hang|so_nguoi_ban|
+-----------+-------------+------------+
|      99441|        96096|        3095|
+-----------+-------------+------------+

+---------------+-----------------+
|so_dong_dang_ky|chua_co_giao_dich|
+---------------+-----------------+
|         102727|             3286|
+---------------+-----------------+
```

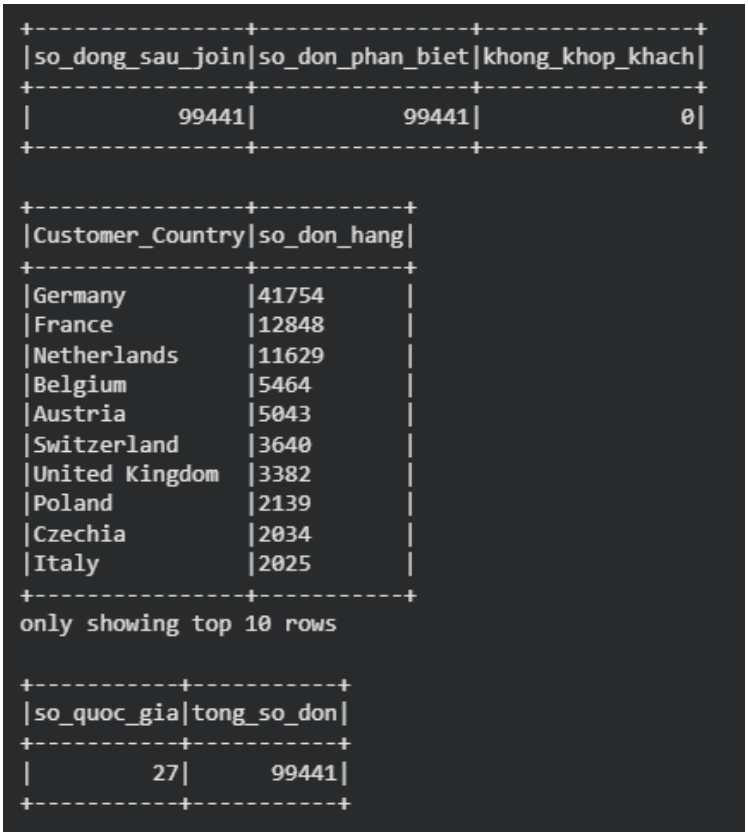
- **Nhận xét kết quả:**
  - Hệ thống ghi nhận 99.441 đơn hàng, được thực hiện bởi 96.096 khách hàng khác nhau và liên quan đến 3.095 người bán.
  - Bảng Customer_List có 102.727 dòng, trong đó 3.286 dòng chưa có mã giao dịch. Số đơn hàng lớn hơn số khách mua cho thấy có những khách hàng đã thực hiện nhiều lần mua sắm, tuy nhiên phần lớn khách hàng chỉ phát sinh một đơn hàng trong dữ liệu.

- **Giải thích: Một khách hàng là một dòng của bảng nào?**
  - Một khách hàng không nhất thiết tương ứng với một dòng trong bảng Customer_List, mà được xác định thông qua mã Subscriber_ID.
  - Cột Customer_Trx_ID biểu diễn mã giao dịch, nên cùng một khách hàng có thể xuất hiện trong nhiều dòng nếu phát sinh nhiều đơn hàng. Ngoài ra, Customer_List còn chứa những người đăng ký nhưng chưa mua hàng. Vì vậy, để xác định chính xác số khách đã mua, cần lọc những người có giao dịch và đếm số Subscriber_ID phân biệt, thay vì đếm toàn bộ số dòng trong bảng.

Bài 3 Số đơn hàng theo quốc gia

- **Phương pháp:**
  - Nối bảng Orders với bảng Customer_List thông qua khóa Customer_Trx_ID để xác định quốc gia của từng đơn hàng. Sử dụng groupBy("Customer_Country") kết hợp count() để thống kê số đơn theo quốc gia, sau đó sắp xếp giảm dần và hiển thị 10 quốc gia đứng đầu.
  - Đồng thời, kiểm tra số bản ghi trước và sau phép nối để bảo đảm không làm mất hoặc nhân đôi đơn hàng.

- **Kết quả thực hiện:**



```
+----------------+---------------+----------------+
|so_dong_sau_join|so_don_phan_biet|khong_khop_khach|
+----------------+---------------+----------------+
|           99441|          99441|               0|
+----------------+---------------+----------------+

+----------------+-----------+
|Customer_Country|so_don_hang|
+----------------+-----------+
|Germany         |41754      |
|France          |12848      |
|Netherlands     |11629      |
|Belgium         |5464       |
|Austria         |5043       |
|Switzerland     |3640       |
|United Kingdom  |3382       |
|Poland          |2139       |
|Czechia         |2034       |
|Italy           |2025       |
+----------------+-----------+
only showing top 10 rows

+-----------+-----------+
|so_quoc_gia|tong_so_don|
+-----------+-----------+
|         27|      99441|
+-----------+-----------+
```

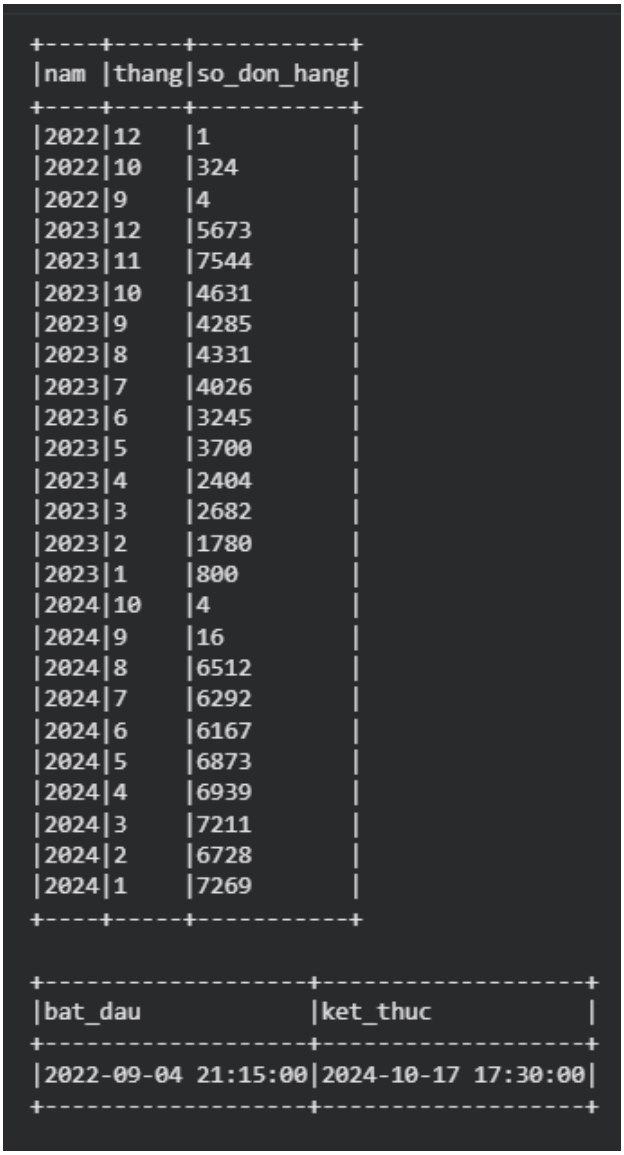
- **Nhận xét kết quả:**
  - Dữ liệu ghi nhận đơn hàng tại 27 quốc gia. Germany đứng đầu với 41.754 đơn, tương đương khoảng 42% tổng số đơn hàng. Tiếp theo là France với 12.848 đơn và Netherlands với 11.629 đơn.
  - Số lượng đơn hàng phân bố không đồng đều giữa các quốc gia, tập trung nhiều nhất tại thị trường Đức. Tổng số đơn sau khi nối dữ liệu vẫn là 99.441 và không có đơn hàng thiếu thông tin khách hàng sau phép nối, cho thấy quá trình kết hợp hai bảng không làm thay đổi số lượng đơn hàng ban đầu.

Bài 4. Số đơn hàng theo năm và tháng

- **Phương pháp:**
  - Sử dụng hai hàm year() và month() để trích xuất năm, tháng từ cột Order_Purchase_Timestamp trong bảng Orders. Sau đó dùng groupBy() và count() để thống kê số đơn hàng theo từng tháng.

- Kết quả được sắp xếp bằng orderBy() theo năm tăng dần và tháng giảm dần. Đồng thời, kiểm tra thời điểm bắt đầu và kết thúc dữ liệu để xác định phạm vi thời gian được ghi nhận.

- **Kết quả thực hiện:**



```
+----+-----+-----------+
|nam |thang|so_don_hang|
+----+-----+-----------+
|2022|12   |1          |
|2022|10   |324        |
|2022|9    |4          |
|2023|12   |5673       |
|2023|11   |7544       |
|2023|10   |4631       |
|2023|9    |4285       |
|2023|8    |4331       |
|2023|7    |4026       |
|2023|6    |3245       |
|2023|5    |3700       |
|2023|4    |2404       |
|2023|3    |2682       |
|2023|2    |1780       |
|2023|1    |800        |
|2024|10   |4          |
|2024|9    |16         |
|2024|8    |6512       |
|2024|7    |6292       |
|2024|6    |6167       |
|2024|5    |6873       |
|2024|4    |6939       |
|2024|3    |7211       |
|2024|2    |6728       |
|2024|1    |7269       |
+----+-----+-----------+

+-------------------+-------------------+
|bat_dau            |ket_thuc           |
+-------------------+-------------------+
|2022-09-04 21:15:00|2024-10-17 17:30:00|
+-------------------+-------------------+
```

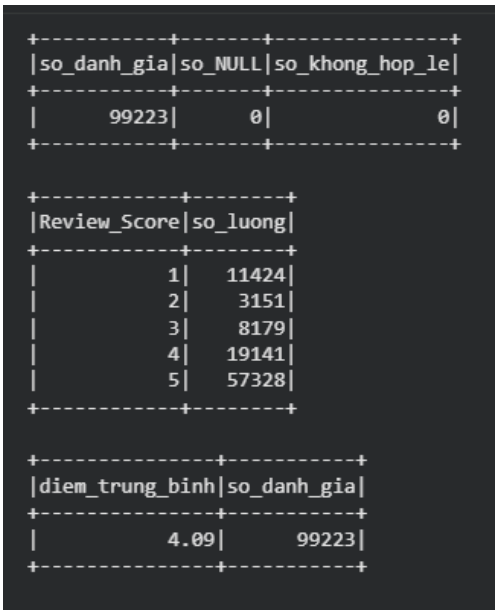
- **Nhận xét kết quả:**
  - Kết quả gồm 25 nhóm năm–tháng trong giai đoạn từ tháng 9/2022 đến tháng 10/2024. Năm 2022 chỉ có dữ liệu tại 3 tháng, còn năm 2024 ghi nhận rất ít đơn vào tháng 9 và tháng 10.

- Trong các tháng có lượng dữ liệu lớn, tháng 11/2023 đạt 7.544 đơn, là mức cao nhất trong bảng thống kê. Nhiều tháng đầu năm 2024 cũng ghi nhận trên 6.000 đơn.
- Tuy nhiên, dữ liệu ở đầu và cuối giai đoạn không đầy đủ, nên không thể dựa vào số đơn rất thấp ở những tháng này để kết luận hoạt động kinh doanh suy giảm. Việc đánh giá xu hướng cần tập trung vào các khoảng thời gian có dữ liệu liên tục và đầy đủ hơn.

Bài 5. Điểm đánh giá trung bình và phân bố theo mức

- **Phương pháp:**
  - Trước khi thống kê, kiểm tra chất lượng cột Review_Score bằng cách sử dụng isNull(), isnan() và isin(1, 2, 3, 4, 5) để phát hiện các giá trị thiếu hoặc nằm ngoài phạm vi hợp lệ.
  - Sau khi xác nhận dữ liệu hợp lệ, sử dụng groupBy("Review_Score") kết hợp count() để thống kê số đánh giá ở từng mức. Điểm trung bình được tính bằng hàm avg() và làm tròn đến hai chữ số thập phân.

- **Kết quả thực hiện:**



```
+-----------+-------+---------------+
|so_danh_gia|so_NULL|so_khong_hop_le|
+-----------+-------+---------------+
|      99223|      0|              0|
+-----------+-------+---------------+

+------------+--------+
|Review_Score|so_luong|
+------------+--------+
|           1|   11424|
|           2|    3151|
|           3|    8179|
|           4|   19141|
|           5|   57328|
+------------+--------+

+---------------+-----------+
|diem_trung_binh|so_danh_gia|
+---------------+-----------+
|           4.09|      99223|
+---------------+-----------+
```

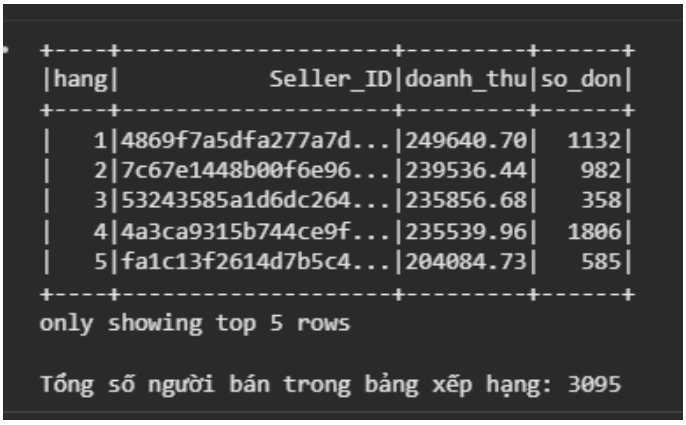
- **Nhận xét kết quả:**
  - Toàn bộ 99.223 bản ghi đánh giá đều có điểm hợp lệ từ 1 đến 5, không phát hiện giá trị NULL hoặc ngoài phạm vi. Điều này cũng cho thấy dữ liệu đánh giá đã được đọc đúng với tùy chọn xử lý bình luận nhiều dòng.

- Điểm trung bình đạt 4,09/5. Mức 5 sao chiếm nhiều nhất với 57.328 đánh giá, tương đương khoảng 57,8%. Tuy nhiên, mức 1 sao vẫn có 11.424 đánh giá, chiếm khoảng 11,5%.
- Nhìn chung, phản hồi tích cực chiếm ưu thế rõ rệt, nhưng vẫn tồn tại một nhóm khách hàng có trải nghiệm không tốt. Sự tập trung lớn ở hai mức điểm này cho thấy mức độ hài lòng của khách hàng có sự phân hóa nhất định.

Bài 6. Xếp hạng người bán

- **Phương pháp:**
  - Sử dụng bảng Order_Items, tính doanh thu cho mỗi dòng hàng bằng tổng Price + Freight_Value, sau đó dùng groupBy("Seller_ID") kết hợp sum() để tính tổng doanh thu của từng người bán.
  - Số đơn hàng được xác định bằng countDistinct("Order_ID") nhằm tránh đếm trùng khi một đơn có nhiều sản phẩm của cùng người bán. Cuối cùng, sử dụng Window.orderBy() kết hợp rank() để xếp hạng theo doanh thu giảm dần và hiển thị 5 người bán đứng đầu.

- **Kết quả thực hiện:**



```
+----+--------------------+---------+------+
|hang|           Seller_ID|doanh_thu|so_don|
+----+--------------------+---------+------+
|   1|4869f7a5dfa277a7d...|249640.70|  1132|
|   2|7c67e1448b00f6e96...|239536.44|   982|
|   3|53243585a1d6dc264...|235856.68|   358|
|   4|4a3ca9315b744ce9f...|235539.96|  1806|
|   5|fa1c13f2614d7b5c4...|204084.73|   585|
+----+--------------------+---------+------+
only showing top 5 rows

Tổng số người bán trong bảng xếp hạng: 3095
```

- **Nhận xét kết quả:**
  - Bảng xếp hạng gồm 3.095 người bán. Người bán đứng đầu đạt doanh thu 249.640,70 từ 1.132 đơn hàng, tiếp theo là người bán hạng 2 với doanh thu 239.536,44 từ 982 đơn.

- Đáng chú ý, người bán hạng 3 và hạng 4 có doanh thu khá tương đồng, lần lượt là 235.856,68 và 235.539,96. Tuy nhiên, số đơn tương ứng là 358 và 1.806, chênh lệch hơn 5 lần.
- Điều này cho thấy hai người bán có cách tạo doanh thu khác nhau: người bán hạng 3 đạt giá trị doanh thu bình quân trên mỗi đơn cao hơn nhiều, trong khi người bán hạng 4 đạt mức doanh thu tương đương nhờ số đơn lớn hơn. Vì vậy, doanh thu và số đơn hàng cần được xem xét đồng thời khi đánh giá hoạt động của người bán.

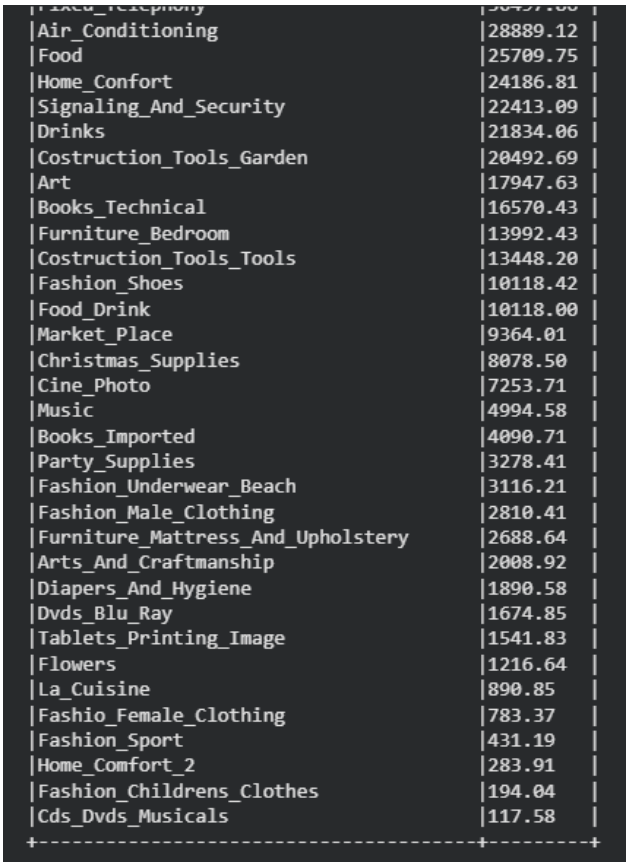
C. Bài tập tự chọn

Bài 7. Doanh thu năm 2024 theo danh mục sản phẩm

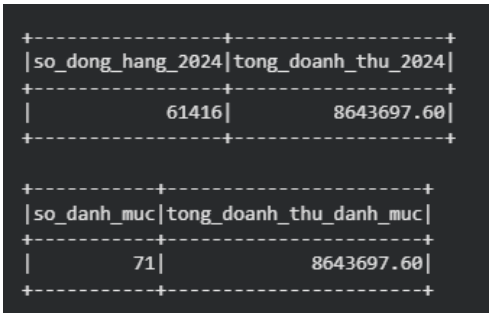
- **Phương pháp:**
  - Nối bảng Order_Items với Orders qua Order_ID để lấy thời gian đặt hàng, đồng thời nối với Products qua Product_ID để xác định danh mục sản phẩm.
  - Sử dụng year("Order_Purchase_Timestamp") để lọc các đơn đặt trong năm 2024. Doanh thu mỗi dòng được tính bằng Price + Freight_Value, sau đó tổng hợp theo danh mục bằng groupBy() và sum(). Kết quả được làm tròn hai chữ số thập phân và sắp xếp giảm dần theo doanh thu.

- **Kết quả thực hiện:**

Product_Category_Name	doanh_thu
Health_Beauty	885191.12
Watches_Gifts	771986.75
Bed_Bath_Table	650794.70
Sports_Leisure	621999.34
Computers_Accessories	594771.04
Housewares	491576.96
Furniture_Decor	476466.13
Auto	404210.57
Baby	299052.56
Cool_Stuff	273910.05
Garden_Tools	259068.32
Telephony	217452.13
Perfumery	204562.54
Toys	200634.07
Office_Furniture	181745.73
Stationery	164743.85
Pet_Shop	152804.94
Construction_Tools_Construction	141187.34
Electronics	134265.45
Musical_Instruments	121476.31
Small_Appliances	97210.18
Home_Appliances_2	96291.60
#N/A	90849.48
Fashion_Bags_Accessories	85091.28
Luggage_Accessories	77374.65
Consoles_Games	72967.50
Home_Construction	69357.77
Computers	67860.80
Home_Appliances	66460.24
Small_Appliances_Home_Oven_And_Coffee	49297.59
Agro_Industry_And_Commerce	47262.18
Construction_Tools_Lights	43867.84
Furniture_Living_Room	42774.14
Industry_Commerce_And_Business	37332.84
Audio	36258.83
Construction_Tools_Safety	35409.30
Kitchen_Dining_Laundry_Garden_Furniture	34951.25
Books_General_Interest	32252.80
Fixed_Telephony	30497.86



Air_Conditioning	28889.12
Food	25709.75
Home_Confort	24186.81
Signaling_And_Security	22413.09
Drinks	21834.06
Costruction_Tools_Garden	20492.69
Art	17947.63
Books_Technical	16570.43
Furniture_Bedroom	13992.43
Costruction_Tools_Tools	13448.20
Fashion_Shoes	10118.42
Food_Drink	10118.00
Market_Place	9364.01
Christmas_Supplies	8078.50
Cine_Photo	7253.71
Music	4994.58
Books_Imported	4090.71
Party_Supplies	3278.41
Fashion_Underwear_Beach	3116.21
Fashion_Male_Clothing	2810.41
Furniture_Mattress_And_Upholstery	2688.64
Arts_And_Craftmanship	2008.92
Diapers_And_Hygiene	1890.58
Dvds_Blu_Ray	1674.85
Tablets_Printing_Image	1541.83
Flowers	1216.64
La_Cuisine	890.85
Fashio_Female_Clothing	783.37
Fashion_Sport	431.19
Home_Comfort_2	283.91
Fashion_Childrens_Clothes	194.04
Cds_Dvds_Musicals	117.58



so_dong_hang_2024	tong_doanh_thu_2024
61416	8643697.60

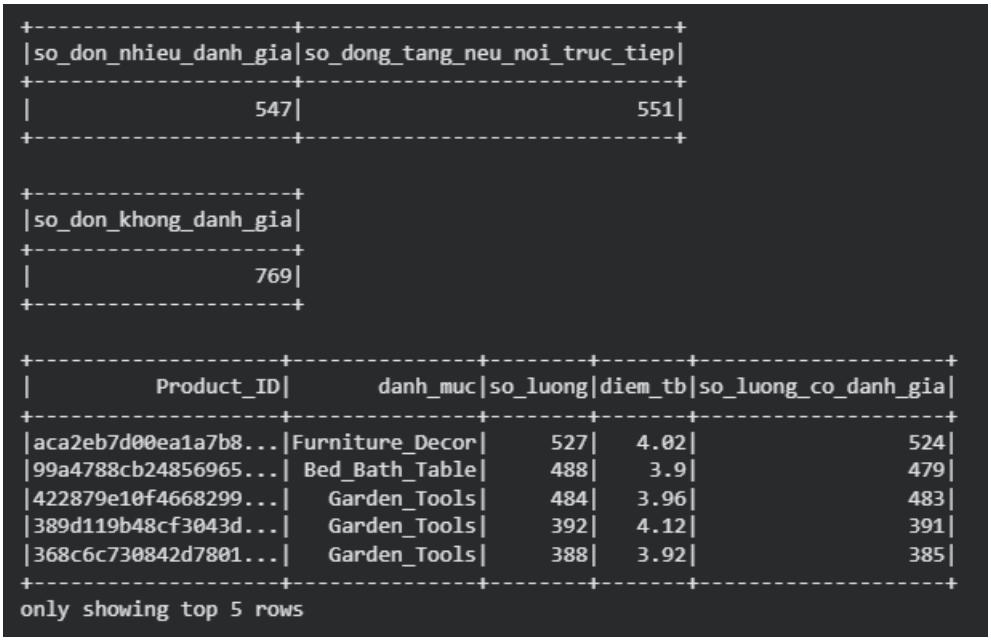
so_danh_muc	tong_doanh_thu_danh_muc
71	8643697.60

- **Nhận xét kết quả:**
  - Năm 2024 ghi nhận 61.416 dòng sản phẩm với tổng doanh thu 8.643.697,60, được phân bổ vào 71 danh mục có phát sinh doanh thu.
  - Danh mục Health_Beauty dẫn đầu với 885.191,12, chiếm khoảng 10,2% tổng doanh thu. Tiếp theo là Watches_Gifts với 771.986,75 và Bed_Bath_Table với 650.794,70.
  - Doanh thu có sự khác biệt đáng kể giữa các danh mục, cho thấy một số nhóm sản phẩm đóng góp lớn hơn vào tổng giá trị bán hàng. Trong kết quả còn xuất hiện danh mục #N/A, phản ánh một số sản phẩm chưa có thông tin phân loại cụ thể trong dữ liệu nguồn.

Bài 8. Sản phẩm bán chạy nhất và điểm đánh giá trung bình

- **Phương pháp:**
  - Sử dụng bảng Order_Items để đếm số lượt bán của từng sản phẩm theo Product_ID. Sau đó nối với Products để xác định danh mục và Order_Reviews để lấy thông tin đánh giá thông qua Order_ID.
  - Trước khi nối, các đánh giá của cùng một đơn hàng được tổng hợp bằng groupBy() và avg() để tránh nhân đôi số dòng sản phẩm khi một đơn có nhiều đánh giá. Sử dụng left join để giữ lại các sản phẩm thuộc đơn chưa có đánh giá, đồng thời tính điểm trung bình chỉ trên các lượt bán có thông tin đánh giá.
  - Cuối cùng, sắp xếp giảm dần theo số lượng bán và lấy 5 sản phẩm đứng đầu.

- **Kết quả thực hiện:**



```
+--------------------+----------------------------+
|so_don_nhieu_danh_gia|so_dong_tang_neu_noi_truc_tiep|
+--------------------+----------------------------+
|                 547|                         551|
+--------------------+----------------------------+

+--------------------+
|so_don_khong_danh_gia|
+--------------------+
|                 769|
+--------------------+

+--------------------+---------------+--------+-------+--------------------+
|          Product_ID|       danh_muc|so_luong|diem_tb|so_luong_co_danh_gia|
+--------------------+---------------+--------+-------+--------------------+
|aca2eb7d00ea1a7b8...|Furniture_Decor|     527|   4.02|                 524|
|99a4788cb24856965...| Bed_Bath_Table|     488|    3.9|                 479|
|422879e10f4668299...|   Garden_Tools|     484|   3.96|                 483|
|389d119b48cf3043d...|   Garden_Tools|     392|   4.12|                 391|
|368c6c730842d7801...|   Garden_Tools|     388|   3.92|                 385|
+--------------------+---------------+--------+-------+--------------------+
only showing top 5 rows
```

- **Nhận xét kết quả:**
  - Sản phẩm bán chạy nhất thuộc danh mục Furniture_Decor với 527 lượt bán và điểm đánh giá trung bình 4,02. Tiếp theo là sản phẩm thuộc Bed_Bath_Table với 488 lượt bán, đạt 3,90 điểm, và sản phẩm thuộc Garden_Tools với 484 lượt bán, đạt 3,96 điểm.
  - Trong Top 5, sản phẩm có 392 lượt bán thuộc Garden_Tools đạt điểm trung bình cao nhất là 4,12. Điều này cho thấy sản phẩm có số lượng bán lớn nhất không nhất thiết cũng là sản phẩm được đánh giá cao nhất.

- Quá trình kiểm tra ghi nhận 769 đơn hàng không có đánh giá và 547 đơn có nhiều hơn một bản ghi đánh giá. Việc tổng hợp điểm theo đơn trước khi nối giúp tránh làm tăng số lượng bán do trùng bản ghi; những đơn chưa có đánh giá không bị gán điểm 0.
- Ngoài ra, điểm đánh giá trong dữ liệu thuộc về toàn bộ đơn hàng chứ không trực tiếp thuộc từng sản phẩm. Vì vậy, điểm trung bình của sản phẩm chỉ mang tính tham khảo, chưa phản ánh hoàn toàn chính xác mức độ hài lòng đối với riêng sản phẩm đó.

D. Bảng so sánh 3 công nghệ

Tiêu chí	Hadoop MapReduce	Spark RDD	Spark DataFrame / Spark SQL
Mô hình xử lý	Xử lý dữ liệu theo các giai đoạn Map và Reduce	Xử lý phân tán thông qua các phép biến đổi trên RDD	Xử lý dữ liệu có cấu trúc dưới dạng bảng và truy vấn SQL
Cấu trúc dữ liệu	Các cặp khóa–giá trị (Key–Value)	Tập dữ liệu phân tán gồm các phần tử	Dữ liệu dạng bảng có tên cột và kiểu dữ liệu
Cách lập trình	Viết Mapper, Reducer và cấu hình Job	Sử dụng map(), filter(), reduceByKey(), join()	Sử dụng select(), filter(), groupBy(), join() hoặc SQL
Tối ưu thực thi	Chủ yếu phụ thuộc vào thiết kế Job và cấu hình	Tối ưu lịch thực thi theo DAG, nhưng không tự hiểu cấu trúc bên trong phần tử	Tự động tối ưu truy vấn bằng Catalyst Optimizer
Quản lý bộ nhớ	Thường ghi kết quả trung gian của các Job xuống đĩa	Có thể lưu dữ liệu trong bộ nhớ bằng cache() hoặc persist()	Quản lý bộ nhớ và tối ưu xử lý dựa trên cấu trúc dữ liệu
Tổng hợp dữ liệu	Sử dụng Reducer để tổng hợp theo khóa	reduceByKey(), groupByKey()	groupBy().agg(), SUM(), COUNT(), AVG()
Nối dữ liệu	Cần tự thiết kế cách nối hoặc sử dụng Distributed Cache	Sử dụng join() hoặc broadcast	Hỗ trợ nhiều kiểu join() và có thể tự tối ưu chiến lược nối
Mức độ phức tạp code	Cao, thường cần nhiều dòng code	Trung bình, ngắn gọn hơn MapReduce	Thấp hơn đối với các bài toán dữ liệu có cấu trúc
Trường hợp phù hợp	Xử lý theo lô với các tác vụ MapReduce	Xử lý dữ liệu cần logic tùy chỉnh hoặc thao tác ở mức phần tử	Phân tích dữ liệu có cấu trúc, thống kê và truy vấn dữ liệu

Nhận xét: Qua 3 bài thực hành, có thể thấy sự khác biệt rõ rệt về cách xử lý dữ liệu giữa các công nghệ. Hadoop MapReduce yêu cầu xây dựng Mapper và Reducer nên quá trình lập trình tương đối phức tạp. Spark RDD giúp đơn giản hóa việc xử lý nhờ các hàm như map(), filter() và reduceByKey(). Trong khi đó, Spark DataFrame và Spark SQL thuận tiện hơn khi làm việc với dữ liệu có cấu trúc, hỗ trợ các phép thống kê, nối bảng và xếp hạng, đồng thời có khả năng tự động tối ưu truy vấn.